

发展论坛

DOI:10.13202/j.cnki.cer.2025.09.020

基于大语言模型的炼化企业生产应急调度研究

官 雨, 杨景政, 宋 忍, 曹 馨
(中国石油大学(北京) 经济管理学院, 北京 102249)



摘 要: 炼化企业生产应急调度是保障生产平稳运行的关键手段, 也是响应国家节能降碳号召的重要保障。当前的生产应急调度以人工为主, 存在人力成本高、依赖知识经验等诸多问题, 因此利用人工智能技术辅助或替代人工有着重要意义。研究了基于大语言模型 (LLM) 的炼化企业生产应急调度模型, 其中主要包括: ① 基于 LLM 的事件抽取模型, 借助 LLM 的上下文学习能力从突发事件文本中抽取关键信息, 然后利用事件抽取模型构建炼化企业生产应急调度知识库。② 结合 LLM 和案例推理 (CBR) 的调度方案生成模型, 依据突发事件的装置、具体描述及影响, 智能选择针对炼化企业应急调度微调过的 LLM 或 CBR 生成调度方案。最后利用某炼化企业实际的《应急调度预案》进行验证, 结果表明基于 LLM 的事件抽取模型能够比较准确地抽取突发事件的关键信息, 所生成的调度方案具有较高的质量, 验证了应急调度模型的可行性和实用性。

关键词: 炼化企业; 生产应急调度; 大语言模型; 案例推理; 微调

中图分类号: F416.21 **文献标志码:** A **文章编号:** 1002-9605 (2025) 09-0099-11

Research on production emergency scheduling of refineries based on large language model

GONG Yu, YANG Jingzheng, SONG Ren, CAO Xin

(School of Economics and Management, China University of Petroleum (Beijing), Beijing 102249, China)

Abstract: The production emergency scheduling of refineries is crucial for smooth operations and responding to national energy conservation and carbon reduction calls. The current production emergency scheduling is mainly manual, which has many problems such as high labor cost and reliance on knowledge and experience. Therefore, it is of great significance to use artificial intelligence technology to assist or replace manual labor. The research on the production emergency scheduling model of refineries based on LLM mainly includes: ① The event extraction model uses the contextual learning ability of LLM to extract key information from the emergency event text, and then uses it to build a knowledge base for the production emergency scheduling of refineries. ② The scheduling plan generation model intelligently selects LLM or CBR that has been fine-tuned for emergency dispatch of refinery production according to the device, description and impact to generate a scheduling plan. Finally, validation based on an actual refinery emergency scheduling plan shows the LLM-based model accurately extracts key information and generates high-quality plans, confirming the emergency scheduling model's feasibility and practicality.

Key words: refineries; production emergency scheduling; large language model; case-based reasoning; fine tuning

0 引 言

炼化企业作为保障国家能源产业供应链的关键一环, 其生产系统的平稳运行对于维持社会运转具有重要的意义。炼化企业生产应急调度是解决炼化企业生产突发事件、保障炼化企业生产安全的关键环节, 也是影响炼化企业节能减排、低碳环保的重

要因素。炼化企业通过生产应急调度能够快速调整生产, 减少因故障导致的额外能耗、提高能源利用效率, 同时也能降低污染物或化学品泄露的风险, 从而为环境保护提供保障。

现有的应急调度往往高度依赖于调度人员, 这种依赖人工的方法存在效率不高、易出错的风险, 并且受限于调度人员个人的经验和能力, 无法确保在所有情况下都能及时下达有效的应急调度指令^[1]。随着人工智能的成熟和数字化的普及, 炼化企业等传统工业面临着产业升级、模式升级、技术

基金项目: 国家自然科学基金资助项目 (72274214); 中国石油大学 (北京) 科研基金资助项目 (2462023YQTD002)

升级的多重挑战和机遇^[2]。

在替代人工应急调度方面常用方法包括案例推理 (Case-Based Reasoning, CBR)^[3-4]、文本挖掘、机器学习以及深度学习等。CBR 是一种基于过去经验知识对解决类似当前问题推理的传统技术,其核心思想在于通过检索并匹配与当前应急情境类似的案例,具有准确高效的优点。但 CBR 存在比较严重的样本局限性,其解决问题的效果取决于案例库中样本的数量和多样性。文本挖掘、机器学习、深度学习等传统人工智能模型难以理解复杂的实际生产情况。因此探索更加高效、准确的基于人工智能的炼化企业生产应急调度模型,已成为一个亟待解决的问题。

当前,大语言模型 (Large Language Model, LLM) 技术正在与多个行业相结合,推动了行业的变革与发展。如在医学领域,XIONG 等^[5]构建了中文医疗对话数据库,并采用低秩自适应技术 (Low-Rank Adaptation, LoRA) 微调 ChatGLM-6B 获得了中文医疗对话语言模型 DoctorGLM,可以理解患者症状,并提供诊断建议、治疗方案等信息;在自动驾驶领域,ZHOU 等^[6]组合了多个大语言模型,基于 LoRA 技术采用自动驾驶领域数据集进行微调,构建了 ELM 模型,为提升自动驾驶模型的感知与场景理解能力做出贡献;在虚假信息检测领域,CHEUNG 等^[7]利用 LORA^[8]技术对开源模型 LLaMA 进行指令微调,增强其对虚假新闻判断逻辑的理解能力。

近年来,人工智能技术在应急调度领域内的应用愈发广泛,这些技术的应用不仅提高了应急指挥调度的智能化水平,也为构建更加安全、智能的应急管理体系奠定了坚实的技术基础。

李从善等^[9]给出停电应急预案层次化的分级分类方案,并在此基础上提出分级检索算法和改进的最近相邻算法相结合的检索策略。刘彤等^[10]利用可扩展标记语言 (XML) 统一表示半结构化应急预案,使用 SIF-Fasttext 算法优先计算同类型应急预案相似度高的各部分章节内容,生成符合该新突发事件的半结构化应急预案。廖佳路等^[11]针对电网应急预案推荐问题,将应急预案推荐问题转换为计算文相似度问题,提出了结合电网领域专有词典与 BERT 模型的方法来完成文本相似度匹配任务。闻爽爽等^[12]采用结构化表示法描述了每起事故的属性,根据事故属性将水灾事故分为 4 类,使用不同的方法计算每种属性的相似度并采用遗传算法对每

个属性的权重进行适当修正,以便更精确地计算出结果。最终使用最邻近算法来计算各种情况的水灾的全局相似性,并将相似度最高的案例解决方案作为目标案例的调度解决方案。

除此之外,一些学者也将其他研究方法应用到应急调度中,如彭其渊等^[13]基于长短期记忆 (LSTM) 网络^[14],提出由序列-序列模型 (seq2seq) 和调度指令修正模块组成的调度指令智能生成模型。WANG 等^[15]利用带有实体掩码的预训练语言模型 (PTM) 与交互式卷积神经网络^[16] (ICNN) 提取应急实体关系,并储存在 Neo4j 图数据库中从而构建应急知识图谱,然后通过采用互信息准则,实现应急预案的智能检索和建议。沈伟等^[17]使用人工智能 RWKV 模型生成应急处置方案,在生成前建立调度命令文本关键信息数据库,便于 RWKV 模型学习特征。

基于上述分析,研究基于 LLM 的炼化企业生产应急调度模型有着重要意义,可以克服传统方法受限于调度人员的知识经验水平及效率低下等问题,本文的主要贡献如下。

- 1) 设计了炼化企业生产应急调度模型,包括事件信息抽取、调度方案生成两个部分。
- 2) 给出了基于 LLM 的事件抽取模型,抽取突发事件的关键信息,并构建炼化企业生产应急调度知识库。
- 3) 本文提出了结合 LLM 和 CBR 的调度方案生成模型,提高应急调度的准确性和灵活性,并通过某炼化企业实际的《应急调度预案》进行了效果验证。

1 基于 LLM 的炼化企业生产应急调度模型

1.1 生产应急调度概述

目前多数炼化企业的生产应急调度流程以人工为主,大致的流程为:工人发现并通过电话汇报问题→调度人员接收汇报→调度人员根据《应急调度预案》得到调度方案→调度人员给相关部门下发调度指令→相关人员执行指令解决问题。其中,调度人员是整个应急调度流程的核心,既负责分析问题也负责下达调度指令。虽然该方式可以实现应急调度的目的,但在 24 小时轮班制中,调度人员可能受到疲劳、精神状态不佳等因素的影响,降低他们的工作效率和决策质量,严重时甚至可能导致操作失误。

人工应急调度的核心是《应急调度预案》,人

工调度会根据《应急调度预案》中的案例给出调度方案，方案中包括对各装置的调度指令。一般来

说生产应急调度案例中包括“问题描述”和“调度方案”2 个部分，如图 1 所示。




图 1 应急调度案例样例

“问题描述”部分规范地描述了生产过程中的突发事件，其中，涉及的装置、具体的事件描述以及事件造成的影响（若有）构成了突发事件的关键信息三元组。

“调度方案”部分介绍了每个突发事件的具体调度安排，由一系列调度指令构成。

但需要注意的是，案例文本与普通文本存在较大的差异，主要体现在其中包含大量炼化企业生产领域的专业术语，如“1 号加氢裂化”。

1.2 基于 LLM 的炼化企业生产应急调度模型设计

LLM 作为人工智能领域的先进技术，自诞生起就在文本生成、语言理解等方面表现出众，能很好地解读用户的目的，迅速地处理复杂的语义查询，高效地回答具有挑战性的问题。

基于此，本文设计基于 LLM 的炼化企业生产应急调度模型，设计思路如图 2 所示，其中包括：基于 LLM 的事件抽取和基于 LLM 和 CBR 的调度方案生成。前者利用事件抽取模型抽取突发事件的关键信息三元组并构建炼化企业生产应急调度知识库，为构建调度方案生成模型提供基础。后者负责生成突发事件对应的调度方案。




图 2 应急调度模型设计思路

由于语音识别、语音合成技术已经相对成熟，可以达到较高的准确率，因此本文重点研究关键信息自动抽取和调度方案自动生成，不涉及对语音自动转成文本信息和方案文本自动转成语音的内容。

1) 关键信息自动抽取。一般的 LLM 模型并没有针对特殊专业领域进行训练，难以准确理解专业术语，难以直接用于专业领域。为了更好地分析和处理应急调度信息，需要构建基于 LLM 的事件抽取模型以自动抽取突发事件中的关键信息，从而为后续调度方案生成奠定基础。

2) 调度方案自动生成。使用人工智能代替调度人员生成调度方案，可以克服传统人工调度存在成本高、受人员经验和水平影响等问题。在已有研究中，CBR 是最常用方法之一，然而该方法只能解决案例库记录过的问题。LLM 作为人工智能领域的前沿技术，具有更加优秀的泛化能力。本文结合了两者的优点，构建基于 LLM 和 CBR 的炼化企业生产应急调度方案生成模型，利用突发事件关键信息生成调度方案。

综上所述，本文给出了基于 LLM 的应急调度模型的总体框架，如图 3 所示，图中左半部分是关键信息自动抽取与知识库构建的流程，右半部分表示调度方案自动生成流程，下文将对 2 个部分详细阐述。

1.3 基于 LLM 的事件抽取模型

应急调度中首要任务是识别突发事件中的关键信息，需要构建事件抽取模型。本文提出事件抽取模型，利用 LLM 的注意力机制更好地捕捉上下文信息提高抽取的准确率。具体而言，针对炼化企业生产应急调度领域，要抽取的目标是：突发事件关键信息三元组。为了引导 LLM 准确抽取突发事件的关键信息，其设计逻辑如图 4 所示。

首先，对案例数据文本进行数据预处理，包括分词和去停用词。

接着，采用 K-means 算法对案例进行聚类，利用手肘法和轮廓系数法并结合实际情况确定聚类簇数 K 为 6，分别为停炉类、停工类、中断类、泄漏类、故障类以及波动类案例。经过聚类后可以让 LLM 学习事件抽取的规则时，引导其注意类别内共性信息和类别间差异性信息，减少对无关信息的关注，从而提高事件抽取模型的效果。

然后，基于聚类结果设计对话形式的样本提示，以历史对话信息的形式提供给 LLM 进行上下文学习，训练基于 LLM 的事件抽取模型。该步骤的关键点是设计有效的样本提示内容。在炼化企业生产应急调度领域，案例中主要是各种专业术语，且结构和类型复杂。为了确保可靠的上下文学习，

本文采用人工抽取的方式来构造样本提示内容。根据聚类获得的类别，在每个类别中各自选择具有代表性的例子，并人工抽取其中的三元组：装置、

事件、影响，作为样本提示的核心内容。表 1 展示了 3 个人工抽取的示例，其中“—”表示案例文本不包含影响部分。




图 3 应急调度模型总体框架




图 4 关键信息抽取设计逻辑

表 1 突发事件三元组示例

类别	示例	装置	事件	影响
停工类案例	PX 装置紧急停工	PX 装置	紧急停工	—
中断类案例	乙烯装置氢气外送中断	乙烯装置	氢气外送中断	—
泄露类案例	乙烯装置脱甲烷塔法兰泄漏造成下游装置停工	乙烯装置脱甲烷塔	法兰泄漏	下游装置停工

在人工抽取示例的关键信息后，分两阶段向 LLM 提供样本提示。第 1 阶段，引导 LLM 成为分类器以辨别案例的类型。第 2 阶段，引导 LLM 成为事件抽取器以抽取突发事件的关键信息三元组。分阶段提供提示旨在合理分配 LLM 的注意力。通过第一阶段的学习，LLM 能够对案例进行准确分类。从而模型在第 2 阶段能够把更多的注意力集中到学习该类别的突发事件抽取规则当中。类似人的学习，逐步细化学习内容可以提高学习效果。图 5 展示了 LLM 通过上下文学习对案例进行分类

的过程。

构建好事件抽取模型后，利用事件抽取模型抽取案例中突发事件的关键信息，将抽取出的关键信息与对应的“调度方案”组合到一起，构建应急调度知识库。图 6 是知识库中的 1 个示例。

1.4 基于 LLM 和 CBR 的调度方案生成模型

调度方案生成模型的目标是根据突发事件的关键信息，调用微调过的 LLM 或 CBR 生成调度方案文本。

在设计调度方案生成模型时主要考虑到结合

CBR 和 LLM 的优点。CBR 具有高效率、易解释的优点，但只能适用于相似案例。LLM 在各种下游任务中表现出优秀的推理和泛化能力，不仅局限于传统案例推理的范式，提供更为灵敏的解决方案。然而，LLM 也存在知识盲区，降低了特定领域的准确性，可解释性与可靠性有待进一步提高。




图5 上下文学习示例




图6 应急调度知识库示例

因此，本文设计了基于 LLM 和 CBR 的调度方案生成模型，如图 7 所示，其逻辑如下。

1) 根据自动抽取突发事件的关键信息三元组，在应急调度知识库进行相似性搜索，计算突发事件关键信息三元组与知识库中案例的相似度。

2) 根据不同的相似度选择不同的调度方案生成方式，相似度设定了 2 个阈值：Thresholds1 与 Thresholds2 (Thresholds1>Threshold2)，2 个阈值需要根据企业的实际情况进行调整，后文中会进行相关阐述。若相似度大于等于 Thresholds1，则使用 CBR 生成调度方案，以确保应急调度效率和调度方案质量；若相似度大于等于 Thresholds2 且小于 Thresholds1，使用微调过的 LLM 生成调度方案。若相似度小于 Thresholds2，表明该突发事件可能属于未知问题，应立即通知调度室值班人员处理。

调度方案生成的核心步骤为：首先，设计相似度计算方法来计算应急调度知识库相似性。其次，基于知识库对 LLM 进行微调，让 LLM 适应炼化企业生产应急调度方案生成特定的下游任务，以输出生成高质量的调度方案。




图7 调度方案生成设计逻辑

在相似度计算方面 Jaccard 是常用指标，然而，在炼化企业生产应急调度领域，同类型的突发事件可能因相关数值不同而导致调度方案不同，需要加大对数值部分的关注力度，因此对 Jaccard 相似度的计算方式做出调整，在计算过程中给予数值更大的权重，当突发事件中的数值在案例中没有交集时，相似度降会显著降低。具体公式见式（1）。

$$jnew(A,B)=\frac{|A\cap B|-Count(i\cap B==NoneforiinS)}{|A|+|B|-|A\cap B|}$$

(1)

式中：A 为突发事件的词组集合；B 为案例的词组集合；S 是 A 中数值的集合，Count 函数是计数函数。

基于上述改进的 Jaccard 相似度计算方法，对输入的三元组中的装置、事件、影响三部分分别进行相似度计算，并分别乘以权重相加。在三元组中，若突发事件的装置部分与案例的装置部分差异

很大，则几乎不能参考该案例，因此给予装置部分的相似度计算结果较大的权重。最终突发事件与案例的相似度计算公式为

$$similarity(x,y)=0.6jnew(x_{dev},y_{dev})+0.2jnew(x_{evnt},y_{evnt})+0.2*jnew(x_{imp},y_{imp})$$

(2)

式中：x 为突发事件；y 为知识库中的案例；下标 dev、evnt、imp 分别为装置、事件、影响。

此处展示一个相似度计算示例，其中计算了原始 Jaccard 相似度和改进 Jaccard 相似度：为“1 号重整 PSA 装置故障”，“2 号重整 PSA 装置故障”计算相似度，原始 Jaccard 相似度为 0.8，而改进 Jaccard 相似度为 0.66。由结果可知，改进 Jaccard 相似度计算方法增加了数值的权重，使计算结果更符合实际。

当相似度大于等于 Thresholds1 时，生成模型会重用具有最高相似度的案例的调度方案，如图 8 所示。




图 8 基于 CBR 的调度方案生成流程

当相似度大于等于 Thresholds2，小于 Thresholds1 时，生成模型将使用 LLM 生成调度方案，由于一般的 LLM 模型无法直接使用，因此需要首先进行 LLM 微调，然后才能调用微调后的 LLM 模型进行调度方案的生成。

1.4.1 针对炼化企业生产应急调度领域的 LLM 微调

尽管 LLM 已经在广泛的任务中展现出令人瞩目的性能，但其训练是基于大规模、多样化的通用数据集进行的，在面对炼化企业生产应急调度领域时难以准确理解其中的专业术语或复杂逻辑，从而无法达到最优性能。重新训练一个 LLM 需要花费大量的时间和计算资源，而微调通常只需要在预训练模型的基础上进行参数调整，而不必从头开始训练整个模型。因此可大幅减少训练所需的时间和计算资源，具有更高的效率。

为了充分发挥 LLM 的潜力，本文采用 LORA (Low-Rank Adaptation) 技术对 LLM 进行微调，LORA 微调是一种重参数化技术，其基本原理是冻结预训练模型的参数，在 Transformer^[18] 架构的每一层中加入一个可训练的旁路矩阵（低秩可分离矩阵），将旁路输出与初始路径输出相加输入到网络

当中，并在微调时只训练这些新增的旁路矩阵参数。其中，低秩可分离矩阵由两个矩阵组成，第一个矩阵负责降维，第二个矩阵负责升维。该方法在微调大型预训练模型具有显著的作用，因其可以显著减少计算资源和时间的需求，还能保持较高的模型性能。

目前常用的微调策略主要有 3 种，分别是监督式微调（SFT）^[19]、指令微调（IT）^[20] 以及基于人类反馈的强化学习微调（RLHF）^[21]，3 种微调策略各有优缺点：SFT 作为传统的 PEFT 方法，相对简单且易于实现，然而微调的效果高度依赖于标注数据的准确性和质量。IT 可以使 LLM 更好地理解业务需求，但其效果也高度依赖于指令的质量和清晰度。RLHF 通过人类的反馈可以使 LLM 学习到更复杂和微妙的行为，从而进一步提高 LLM 在下游任务中的表现，然而 RLHF 的实现更加复杂、训练成本更高。

综上所述，本文基于知识库，使用 LORA 微调作为主要的微调手段，对 LLM 分别进行 SFT 微调、IT 微调以及 RLHF 微调。微调策略如图 9 所示。

其中，SFT 和 IT 的区别主要体现在 SFT 倾向




图 9 微调策略

于让 LLM 适应下游任务而 IT 更倾向于让 LLM 更专注于用户提供的指令。相比之下，RLHF 与 SFT、IT 有本质的区别，RLHF 有 2 个核心内容：奖励模型和近端策略优化算法。奖励模型（Reward Model，RW）负责将人类评估者的反馈转换为一个可以被强化学习算法使用的奖励信号。近端策略优化算法（Proximal Policy Optimization，PPO）是一种强化学习算法。其核心思想如下：在策略迭代的过程中，不仅需要考虑如何最大化长期奖励，还要考虑当前策略与新策略之间的差异。具体来说，PPO 在预期收益乐观时保持谨慎，在预期收益悲观

的情况下，也会保持一定的严谨性。因此，PPO 算法可以被视为一种保守的约束。

基于奖励模型和 PPO 算法，RLHF 可以被划分为 3 个阶段：初步微调、训练奖励模型、使用强化学习算法进一步优化模型。基于此，本文设计的 RLHF 微调流程如下。

首先，利用 IT 对 LLM 进行初步微调，记录其回答并对这些回答进行评价。将评价结果排序、整理为反馈数据集。在反馈数据集中每个案例都由“一问两答”组成，其中第一个答案优于第二个答案。其次，利用反馈数据集训练一个 RW 来捕捉和量化评估者的偏好。RW 生成的奖励信号可以作为反馈数据提供给 PPO，为 PPO 提供了调整模型的依据。最终，PPO 利用反馈信号进一步调整经过初步微调的 LLM 的参数。整个过程如图 10 所示，该过程旨在反复优化 LLM，使其生成结果能够更加贴合评估者偏好的行为。




图 10 RLHF 微调流程


1.4.2 基于微调过的 LLM 的生产应急调度方案生成

LLM 生成文本是通过 Transformer 架构预测下一个单词或字符的过程，下面的内容是从 Transformer 架构的角度阐述 LLM 生成。其中编码层负责理解输入序列，解码层负责生成输出序列。在使用 LLM 生成调度方案时，首先输入的突发事件三元组会经过编码器中多个编码层（Encoder）的处理被转换为一系列的向量表示，向量包含了输入序列的语义信息以及装置、事件、影响之间的关联强度，并构成隐藏层。隐藏层不直接与外部交互，而是负责提取和转换输入数据中的特征，并将这些特征传递给解码器。其次解码器中的多个解码层（Decoder）会将隐藏层中的内容映射为自然语言序列，得到解码器的输出。解码器的输出先经过

线性变换，后经过 Softmax 激活函数处理，从而得到一个概率分布。在此基础上，通过词典映射，选出概率最高的单词作为预测输出，从而逐词生成完整的调度方案。图 11 为 LLM 生成调度方案文本的原理示意。

2 调度模型效果验证与分析

为了验证所提出的应急调度模型的效果，利用国内某大型炼化企业《应急调度预案》中生产应急调度部分的全部案例，共计 76 条 25 000 余字，涵盖了炼化生产中的蒸汽系统、氮气系统、氢气系统、燃料气系统、储运系统、生产装置 6 个类别。每个案例由“问题描述”和“调度方案”两部分组成，均采用规范化的表述，并且内容言简意赅，



便于快速专业调度人员调度时查阅、使用。

由于 LLM 已经事先在大规模通用知识上完成了预训练，所以在实际任务中只需要利用少量的样本对其进行微调就可以取得良好的效果。接下来在上述实际数据上展开了相关实验，实验环境配置见表 2。

表 2 实验环境

组件	配置
OS	Ubuntu 22.04
CPU	8 Core 2.90GHz
GPU	NVIDIA A10 24G
Python	3.10.13
Transformer	4.37.2
LLM	ChatGLM3-6B

2.1 评估指标

本文使用 ROUGE 指标来评估事件抽取模型和调度方案生成模型的效果，包括 ROUGE-N 和 ROUGE-L。ROUGE-N 是将模型输出结果和参考文本按照 N-gram 拆分后计算相似度指标。其中，N 可以是 1、2，分别表示基于单个词的重叠情况、相邻的两个词的重叠情况来评估模型输出结果与参考文本的相似性。ROUGE-L 通过衡量模型输出结果与参考文本的最长公共子序列的重叠情况来评估它们的相似性。具体包括以下 3 种相似度计算方式。

1) 召回率 (Recall)。其衡量的是模型输出结果涵盖了多少参考文本的内容。计算方式是模型输出结果与参考文本重叠部分占参考文本总长

度的比例。

$$Recall = \frac{TP}{TP + FN} \tag{3}$$

式中：TP (True Positive) 为模型输出结果与参考文本重叠的内容；FN (False Negative) 为模型输出结果没有而参考文本有的内容。

2) 准确率 (Precision)。其衡量模型输出结果与参考文本匹配的内容有多少。计算方式是模型输出结果与参考文本重叠的部分占模型输出结果总长度的比例。

$$Precision = \frac{TP}{TP + FP} \tag{4}$$

式中：TP 为模型生成结果与参考文本重叠的内容；FP (False Positive) 为模型输出结果有而参考文本没有的内容。

3) F1 分数 (F1-score)。F1 分数也是一种衡量模型性能的方法，是召回率和准确率的调和平均数。

$$F1 = \frac{2 \times Recall \times Precision}{Recall + Precision} \tag{5}$$

分别计算 ROUGE-1、ROUGE-2、ROUGE-L 对应的召回率、准确率、F1 分数，然后计算平均召回率、准确率、F1 分数作为 ROUGE 得分。通常情况下，ROUGE 得分越高，表示模型输出结果与参考文本之间的相似度越高，也就代表模型输出的结果质量越好。

2.2 事件抽取模型的效果验证与分析

为保证评估结果的客观性，本文将知识库作为评估数据集，人工抽取案例的关键信息构建参考数据集，通过对比机器自动抽取的关键信息与人工抽取的关键信息，能够准确地评估自动抽取的精度。使用 ROUGE-1、ROUGE-2 和 ROUGE-L 3 个指标，分别计算装置、事件和影响 3 部分的召回率 (Recall)、准确率 (Precision) 和 F1 分数 (F1)。对 3 个指标的计算结果取平均作为 ROUGE 得分。最终对评估数据集中每个案例的 ROUGE 得分取平均作为总 ROUGE 得分，评估结果见表 3。

表 3 事件抽取模型评估结果

三元组	装置	事件	后果
Recall	1	1	1
precision	1	0.964	1
F1	0.99	0.974	0.99

由表 3 可知，装置、事件和影响 3 部分的召回

率、准确率和 $F1$ 分数均在 96% 以上，表明本文设计的事件抽取模型可以精准地抽取突发事件的关键信息，证明了基于 LLM 的事件抽取模型的可行性。

此外，为了确定 $Thresholds_1$ 的合理阈值，本文计算了上述人工抽取参考数据集与评估数据集的案例之间的改进 Jaccard 相似度，发现最低为 90%。因此可以将 $Thresholds_1$ 设置为 90%，即当新出现的突发事件的与知识库中某个案例的改进 Jaccard 相似度大于等于 90% 时，可以使用 CBR 生成调度方案。

例如，某突发事件文本为“0.85 MPa 氮气系统发生故障”，经过知识库相似性搜索发现，该突发事件与知识库中“0.85 MPa 氮气系统故障”案例最为相似，相似度为 90%。因此使用 CBR 生成调度方案，重用该案例的调度方案，无需进一步计算。

2.3 调度方案生成模型的效果验证与分析

在调度方案生成中重点探讨 LLM 的相关部分。在实验中将知识库中 15% 的案例作为测试集，其余案例作为训练集用于微调 LLM。

本文对调度方案生成模型的评估将从如下 2 个方面展开。

- 1) 学习效果，旨在了解 LLM 经过微调学习所掌握的知识量，通过在训练集上进行评估实现。
- 2) 泛化效果，旨在了解 LLM 在遇到未曾学习

过的问题时的表现，通过在测试集上进行评估实现。

与评估事件抽取模型类似，本文计算 ROUGE-1、ROUGE-2、ROUGE-L 3 个指标的召回率 ($Recall$)、准确率 ($Precision$) 和 $F1$ 分数 ($F1$)，对 3 个指标的计算结果取平均值得到 ROUGE 得分。最终将训练集或测试集中的所有案例的 ROUGE 得分取平均得到总 ROUGE 得分。对学习能力的评估结果见表 4。

表 4 学习效果评估结果

微调策略	SFT	IT	RLHF
$Recall$	0.855	0.911	0.92
$precision$	0.900	0.931	0.939
$F1$	0.865	0.914	0.922

由表 4 可知，经过 3 种微调的 LLM 的召回率、准确率、 $F1$ 分数均大于 84%，尤其是 RLHF，3 种指标均大于 92%，表明经过 RLHF 微调的 LLM 能够比较准确地回答学习过的问题。与此同时，在测试集上评估经过 RLHF 微调的 LLM 的泛化能力，除了计算 ROUGE 得分，本文使用改进 Jaccard 相似度计算方法来计算测试集中每个案例与训练集中所有案例的最高相似度，选取其中具有代表性的案例进行展示，结果见表 5。

表 5 泛化能力评估结果

Jaccard	0.3	0.35	0.6	0.6	0.66	0.66
$Recall$	0.212	0.199	0.876	0.951	0.915	0.948
$Precision$	0.323	0.371	0.967	0.892	0.922	0.938
$F1$	0.247	0.256	0.92	0.921	0.918	0.943

由表 5 可知，ROUGE 得分随着相似度的增加而增加，符合预期，因为相似度越大说明微调过的 LLM 对相关知识的学习更深入。同时注意到当表中相似度大于等于 60% 时，ROUGE 得分基本能保持在 90% 以上，说明此时 LLM 生成的调度方案具有较高的可行性，因此将 $Thresholds_2$ 估计为 60%。

例如，测试集中某案例文本为“3.35 MPa 氮

气系统故障”，此案例未用于训练，因此需要计算相似度，发现该案例与训练集中“0.85 MPa 氮气系统故障”案例最为相似，相似度为 60%。因此使用经过 RLHF 微调过的 LLM 生成调度方案，为了说明 LLM 生成调度方案的有效性，需要对比原有调度方案与 LLM 生成的内容。此处给出原有的《应急预案》中对此案例的调度方案，如图 12 所示。

"问题描述": "3.35 MPa氮气系统发生故障";
"调度方案": "① 立即联系林德空分装置，立即恢复3.35 MPa氮气管网压力；② 迅速汇报相关领导，根据影响范围决定是否启动相应应急预案；③ 若是压力迅速下降或者中断，要求立即启用林德事故液氮系统；④ 通知全厂各装置密切关注3.35 MPa氮气压力；⑤ 根据氮气管网压力下降情况，通知各装置控制氮气用量、暂停非必要氮气使用(有干燥剂或催化剂再生的装置则立即停止使用氮气)，并做好启动 0.85 MPa 氮气中断应急预案准备。"

图 12 原有的调度方案

而使用 RLHF 微调过的 LLM 生成的调度方案，如图 13 所示。




图 13 LLM 生成调度方案

对比两者（图中加黑的部分为存在差异的部分），可以发现 LLM 生成的调度方案，接近于原有的方案，说明 LLM 生成的调度方案有效。

针对上述的实际案例，计算 LLM 生成调度方案与原调度方案的 ROUGE-1、ROUGE-2、ROUGE-L3 个评估指标，结果显示平均召回率为 0.95，平均精确度为 0.89，平均 F1 分数为 0.92。说明二者比较相似，同时通过实例证明了将 Thresholds2 估计为 60%具有可行性和有效性。

3 结 论

本文研究了炼化企业生产应急调度，提出基于 LLM 的应急调度模型，关键内结论如下。

1) 设计了基于 LLM 的事件抽取模型。能够自动的从突发事件中抽取其中的关键信息，并在此基础上构建炼化企业生产应急调度知识库。

2) 设计了自动的调度方案生成模型。通过对 LLM 进行微调，使其能够适应炼化企业生产应急调度该特定的下游任务，根据事件相似性自动生成调度方案。

3) 在某炼化企业生实际生产应急调度案例上开展相关验证。结果表明所设计的事件抽取模型能够比较准确地抽取突发事件的关键信息；同时针对与知识库中案例最高相似度大于等于 60%的突发事件，利用经过 RLHF 微调的 LLM 所生成的调度方案比较合理，其 ROUGE 得分基本可以保持在 90%以上，验证了本文设计的事件抽取模型和调度方案生成模型的可行性与实用性，为提高炼化企业生产应急调度的效率和质量贡献了力量。

4) LLM 能够有效处理复杂的决策问题，但其在应急调度中的应用较少，本文已经在突发事件的理解以及调度方案的自动生成做了相关的探索。未来，可以结合强化学习对 LLM 进行进一步微调，使其更好地适应实际场景中的动态变化和 108

复杂需求。例如，通过引入人工反馈机制，LLM 可以不断优化其决策逻辑，提高对突发事件的响应速度和准确性。此外，LLM 还可以与迁移学习深度融合，通过迁移学习，可以将 LLM 在通用领域的知识迁移到特定应急场景中，也可以扩展到能源行业其他领域如：煤炭、电力、石油天然气的生产应急调度中。

参考文献：

[1] 石 赫, 杨 群, 刘绍翰, 等. 基于深度学习的电网故障预
案信息抽取研究[J]. 计算机科学, 2020, 47 (S2): 52-56.

[2] 李 婧, 于小茜. 智能炼化工厂建设架构的研究[J]. 化工管
理, 2021 (20): 174-175.

[3] 刘 健. 基于案例推理的知识系统的设计与实现[D]. 南京:
南京航空航天大学, 2004.

[4] 侯玉梅, 许成媛. 基于案例推理法研究综述[J]. 燕山大学学
报 (哲学社会科学版), 2011, 12 (4): 102-108.

[5] XIONG H L, WANG S, ZHU Y T, et al. Doctorglm: fine-tun-
ing your chinese doctor is not a herculean task[EB/OL]. (2023-
04-03)[2024-12-13]. https://arxiv.org/abs/2304.01097.

[6] ZHOU Y, HUANG L, BU Q, et al. Embodied understanding of driv-
ing scenarios[C]. European Conference on Computer Vision.
Cham: Springer Nature Switzerland, 2024: 129-148.

[7] CHEUNG T H, LAM K M. Factllama: optimizing instruction-fol-
lowing language models with external knowledge for automated fact-
checking [C]. 2023 Asia Pacific Signal and Information
Processing Association Annual Summit and Conference (APSIPA
ASC), IEEE, 2023: 846-853.

[8] HU E J, SHEN Y, WALLIS P, et al. LORA: low-rank ada-
ptation of large language models[J]. ICLR, 2022, 1 (2): 3.

[9] 李从善, 刘天琪, 李兴源. 停电应急预案快速匹配与智能生
成方法[J]. 电力自动化设备, 2014, 34 (1): 32-36, 42.

[10] 刘 彤, 陈思源, 倪维健. 基于 SIF-Fasttext 算法的应急预
案快速生成[J]. 中国科技论文, 2020, 15 (11): 1270-
1276.

[11] 廖佳路. 基于 BERT 的电网故障事件抽取与应急预案推荐方
法研究[D]. 武汉: 武汉科技大学, 2020.

[12] 闻爽爽. W 煤矿水灾事故应急预案智能推荐研究[D]. 阜新: 辽宁工程技术大学, 2022.

[13] 彭其渊, 胡雨欣, 鲁工圆. 基于预警文本信息的调度命令智能生成模型[J]. 同济大学学报 (自然科学版), 2020, 48 (9): 1328-1335, 1363.

[14] HOCHREITER S, SCHMIDHUBER J. Long short-term memory [J]. Neural Computation, 1997, 9 (8): 1735-1780.

[15] WANG L, LIU X, LIU Y, et al. Knowledge-driven intelligent recommendation method for 12 emergency plans in water diversion projects[J]. Journal of Hydroinformatics, 2023, 25 (6): 2522-2540.

[16] NESHATPOUR K, BEHNIA F, HOMAYOUN H, et al. ICNN: an iterative implementation of convolutional neural networks to enable energy and computational complexity aware dynamic approximation [C]. 2018 Design, Automation & Test in Europe conference & exhibition. IEEE, 2018: 551-556.

[17] 沈 伟. 基于自然语言处理的铁路应急处置方案编制[D]. 兰州: 兰州交通大学, 2023.

[18] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [J]. Advances in Neural Information Processing Systems, 2017, 31: 6000-6010.

[19] LIM J Y, LIM K M, LEE C P, et al. Sft: few-shot learning via self-supervised feature fusion with transformer [J]. IEEE Access, 2024, 12: 86690 - 86703.

[20] CHUNG H W, HOU L, LONGPRE S, et al. Scaling instruction-finetuned language models [J]. Journal of Machine Learning Research, 2024, 25 (70): 1-53.

[21] BAI Y, JONES A, NDOUSSE K, et al. Training a helpful and harmless assistant with reinforcement learning from human feedback[EB/OL]. (2022-04-12) [2024-12-13]. <https://arxiv.org/abs/2204.05862>.

作者简介: 宫 雨 (1976—), 男, 山东蓬莱人, 博士, 副教授, 硕士生导师, 主要研究方向为数据挖掘、能源数据分析。E-mail: gongyu@cup.edu.cn

责任编辑: 刘萌萌